Qué ve el kernel

La representación de la fuente con y sin BatchNorm,
y por qué decide el resultado de la adaptación

En una línea. Sin BatchNorm el codificador de la fuente entrega al kernel un espacio de *una* dirección efectiva para un problema de *tres* clases. Tres clases sobre una recta no se pueden separar con ningún kernel de distancia: la del medio queda entre las otras dos por construcción. No es un problema de sintonía — es geometría, y se resuelve antes de que al kernel se le pregunte nada.

1. Las tablas, primero

Todas las medidas salen de **la fuente sola**, al terminar la fase 1: mismo seed, mismos datos, mismo orden de lote. Lo único distinto entre las dos columnas es BatchNorm. Las dos alcanzan **1.0000** de acierto sobre la fuente, así que lo que difiere no es el ajuste sino la forma de lo que se le entrega al kernel.

Sin el término KL

SIN BatchNorm

familia	dim. ef.	% entre	contraste	acierto
rollo	1.97	92.3 %	0.4383	0.9401 ± 0.109
toroides	1.11	95.5 %	0.5536	0.3651 ± 0.030
lunas	1.04	99.9 %	0.5799	0.3306 ± 0.006

CON BatchNorm

familia	dim. ef.	% entre	contraste	acierto
rollo	1.97	99.1 %	0.4246	0.6769 ± 0.014
toroides	1.86	91.3 %	0.4757	0.6299 ± 0.098
lunas	1.95	99.8 %	0.4228	0.4988 ± 0.133

Con el término KL

SIN BatchNorm, con KL

familia	dim. ef.	% entre	contraste	acierto
rollo	2.81	81.9 %	0.3580	0.7355 ± 0.251
toroides	2.83	80.7 %	0.3622	0.2781 ± 0.068
lunas	2.33	90.5 %	0.3946	0.3346 ± 0.006

CON BatchNorm, con KL

familia	dim. ef.	% entre	contraste	acierto
rollo	2.80	82.0 %	0.3595	0.9451 ± 0.079
toroides	2.83	81.3 %	0.3606	0.7657 ± 0.206
lunas	2.83	80.8 %	0.3605	0.7062 ± 0.109

dim. ef. son las direcciones efectivas (de 1 a 16); *% entre* es la parte de la varianza que es separación entre clases; *contraste* es $\bar{K}_{=} - \bar{K}_{\neq}$; *acierto* es sobre el dominio objetivo, 5 semillas. El azar es 0.3333.

2. Qué experimento se hizo

Tres familias de juguete (*rollo*, *toroides*, *lunas*), reducidas a **3 clases**. Cada una tiene un dominio fuente y uno objetivo; el objetivo es el mismo generador con una traslación de 5,0 por coordenada, una rotación de 45° y ruido $\sigma = 0{,}3$.

El montaje son dos fases. La fase 1 entrena *un* codificador $f_\theta : \mathbb{R}^d \to \mathbb{R}^{16}$ y una cabeza lineal sobre la fuente, con entropía cruzada, y **congela los dos**. Una copia única siembra el codificador objetivo $f_{\theta'}$, que de ahí en más entrena libre bajo el término de adaptación, que es la única fuerza que lo toca. La fuente siempre pasa por su codificador congelado y el objetivo por el suyo.

Lo que se mide acá es la fase 1 sola. No hay dominio objetivo, no hay adaptación, no hay segundo codificador: solo las 16 coordenadas que el codificador de la fuente produce, y lo que un kernel gaussiano puede hacer con ellas.

3. Qué muestra cada tabla

3.1. La geometría: direcciones efectivas y separación

La covarianza de los rasgos de la fuente, $\Sigma_s = \frac{1}{n}\sum_i (z_i - \bar{z})(z_i - \bar{z})^\top$, se descompone en

$$\Sigma_s \;=\; \underbrace{\Sigma_{\text{dentro}}}_{\text{dispersión de cada clase}} \;+\; \underbrace{\Sigma_{\text{entre}}}_{\text{separación entre clases}} \quad .$$

De ahí salen dos números. El primero es la **razón de participación** sobre los autovalores $\lambda_1 \geq \cdots \geq \lambda_{16}$ de Σ_s,

$$\dim_{\text{ef}} \;=\; \frac{(\sum_k \lambda_k)^2}{\sum_k \lambda_k^2} \;\in\; [1, 16],$$

que vale 1 si toda la varianza está en una dirección y 16 si es isótropa. Es libre de escala: multiplicar los rasgos por cualquier constante no la mueve, así que no confunde "se encogió" con "se aplastó". El segundo es $\operatorname{tr}\Sigma_{\text{entre}}/\operatorname{tr}\Sigma_s$, la fracción de la varianza que *es* separación de clases.

3.2. Lo que el kernel consume

SIN BatchNorm

familia	σ	rango	sat.	$\bar{K}_{=}$	$\bar{K}_{\neq}$
rollo	49.2	45	25.7 %	0.9667	0.5283
toroides	23.6	97	26.0 %	0.9674	0.4137
lunas	19.4	1421	33.3 %	0.9989	0.4190

CON BatchNorm

familia	σ	rango	sat.	$\bar{K}_{=}$	$\bar{K}_{\neq}$
rollo	17.0	135	33.3 %	0.9967	0.5722
toroides	17.4	89	23.9 %	0.9551	0.4794
lunas	16.8	733	33.3 %	0.9991	0.5763

SIN BatchNorm, con KL

familia	σ	rango	sat.	$\bar{K}_{=}$	$\bar{K}_{\neq}$
rollo	14.4	7	6.4 %	0.9303	0.5723
toroides	13.9	7	4.2 %	0.9225	0.5603
lunas	13.8	45	24.9 %	0.9638	0.5692

CON BatchNorm, con KL

familia	σ	rango	sat.	$\bar{K}_{=}$	$\bar{K}_{\neq}$
rollo	14.3	7	6.1 %	0.9306	0.5712
toroides	14.0	7	4.2 %	0.9263	0.5657
lunas	14.4	21	10.7 %	0.9242	0.5637

El término usa un kernel gaussiano de instancia,

$$k(x, y) \;=\; \exp\!\left(-\frac{\|x - y\|^2}{2\sigma^2}\right),$$

con **un solo** σ para los tres bloques K^s, K^t y K^{st} — porque los tres derivan del mismo kernel de instancia, y mezclar anchos rompe la semidefinición positiva de la matriz conjunta, con lo cual H_2 dejaría de ser la entropía de nada. Con `auto`, σ es la mediana de las distancias por pares. *rango* es el cociente entre el percentil 99 y el 1 de esas distancias: dice cuánto tendría que cubrir ese único σ. *sat.* es el porcentaje de pares con $k > 0{,}95$, que el kernel ya no distingue.

Un hecho que conviene tener presente: k depende solo de $\|x - y\|$, así que trasladar un dominio entero *no mueve ninguna distancia dentro de ese dominio.* Está medido: trasladar el objetivo por los 95,06 de la brecha cambia K^t en $8{,}3 \times 10^{-6}$ y K^{st} en 0,9995. De los tres bloques, uno solo ve un desplazamiento de medias.

3.3. El contraste a nivel de clase, donde se ve la recta

SIN BatchNorm

familia	$K(0,1)$	$K(0,2)$	$K(1,2)$
rollo	0.5863	0.5012	0.4974
toroides	0.1386	0.5413	0.5613
lunas	0.1222	0.6139	0.5208

CON BatchNorm

familia	$K(0,1)$	$K(0,2)$	$K(1,2)$
rollo	0.5712	0.5799	0.5654
toroides	0.4300	0.4732	0.5351
lunas	0.5498	0.5860	0.5931

SIN BatchNorm, con KL

familia	$K(0,1)$	$K(0,2)$	$K(1,2)$
rollo	0.5676	0.5710	0.5784
toroides	0.5587	0.5594	0.5628
lunas	0.5694	0.5699	0.5682

CON BatchNorm, con KL

familia	$K(0,1)$	$K(0,2)$	$K(1,2)$
rollo	0.5779	0.5698	0.5659
toroides	0.5674	0.5664	0.5632
lunas	0.5526	0.5675	0.5710

$K(a,b)$ es el valor medio del kernel entre la clase a y la b. Esa matriz de 3×3 es, literalmente, **todo lo que un método de kernel sabe de las clases**: los pesos por confianza de la Ec. (24), la normalización por trazas de la Ec. (32), las cotas L_c y U_c de la Ec. (35) y la mezcla marginal/condicional leen todos esta misma matriz, ninguno la produce.

Con BatchNorm los tres pares quedan a menos de 0,09 unos de otros: las tres clases están aproximadamente equidistantes, un **triángulo en un plano**. Sin BatchNorm, en toroides y lunas, un par queda en 0,12–0,14 y los otros dos en 0,52–0,61, casi iguales entre sí. Esa es la firma de **tres puntos ordenados sobre una recta**: los dos extremos lejos, y el del medio cerca de ambos.

Y ahí está el problema, que es geométrico y no de ajuste. Si los tres centroides son colineales, existe $t \in (0,1)$ con $\mu_2 = t\mu_0 + (1-t)\mu_1$, y entonces la clase del medio *no puede* estar lejos de las dos a la vez. El kernel la ve parecida a ambas, y desde su punto de vista los extremos son indistinguibles. Para que C clases puedan ser mutuamente separables hacen falta al menos $C-1$ direcciones efectivas **antes** de calcular el kernel.

4. ¿Se arregla poniendo BatchNorm en una sola capa?

La red es

$$\text{Lin}(d,32)\ [\text{BN}]\ \text{ReLU}\ \ \text{Lin}(32,32)\ [\text{BN}]\ \text{ReLU}\ \ \text{Lin}(32,16)\ [\text{BN}],$$

así que hay tres lugares posibles. El tercero, sobre la salida de 16 dimensiones, es el único que normaliza *exactamente lo que el kernel lee*, y no estaba en la arquitectura: se agregó como brazo propio.

		sin KL		con KL	
familia	BatchNorm en	dim. ef.	acierto	dim. ef.	acierto
rollo	ninguna	1.97	0.9401 ± 0.109	2.81	0.7355 ± 0.251
	1.ª capa	1.89	0.9355 ± 0.129	2.76	1.0000 ± 0.000
	2.ª capa	1.99	0.7321 ± 0.226	2.83	0.9846 ± 0.031
	salida	2.01	0.4590 ± 0.165	3.11	0.9679 ± 0.064
	ambas ocultas	1.97	0.6769 ± 0.014	2.80	0.9451 ± 0.079
toroides	ninguna	1.11	0.3651 ± 0.030	2.83	0.2781 ± 0.068
	1.ª capa	1.68	0.7222 ± 0.055	2.79	0.7157 ± 0.139
	2.ª capa	1.90	0.4176 ± 0.088	2.85	0.3448 ± 0.223
	salida	2.06	0.5830 ± 0.130	3.16	0.4046 ± 0.110
	ambas ocultas	1.86	0.6299 ± 0.098	2.83	0.7657 ± 0.206
lunas	ninguna	1.04	0.3306 ± 0.006	2.33	0.3346 ± 0.006
	1.ª capa	1.17	0.6534 ± 0.093	2.63	0.8398 ± 0.038
	2.ª capa	1.92	0.3731 ± 0.068	2.81	0.4080 ± 0.171
	salida	2.00	0.2367 ± 0.057	2.80	0.2225 ± 0.106
	ambas ocultas	1.95	0.4988 ± 0.133	2.83	0.7062 ± 0.109

Sí se arregla, y el lugar es la primera capa. Sin KL, pasar de ninguna a la primera lleva toroides de 0,3651 a **0,7222** y lunas de 0,3306 a **0,6534** — por encima de ponerlo en *las dos* capas ocultas, que es la configuración con la que veníamos trabajando.

Y la salida es el peor lugar de todos, que es lo contrario de lo que sugiere la intuición: normalizar justo los números que el kernel consume da 0,4590 en rollo y 0,2367 en lunas, por debajo de no poner ninguno. Una normalización sobre la salida fija la escala por coordenada *después* de que la representación ya se formó; no reparte la varianza entre direcciones, solo reescala el aplastamiento que ya estaba. La primera capa, en cambio, actúa cuando la representación todavía se está construyendo.

5. Conclusión

1. **Al kernel no le falta señal sin BatchNorm; le sobra.** El contraste $\bar{K}_{=} - \bar{K}_{\neq}$ es *mayor* sin BatchNorm en toroides y lunas. La saturación es la misma en todos los brazos y casi nada muere. Así que σ, el rango dinámico y la saturación — los sospechosos de siempre — no son la diferencia.

2. **La diferencia es la dimensionalidad efectiva.** Las dos familias que fracasan sin BatchNorm ponen el 94,8 % y el 97,9 % de la varianza en una sola dirección, con 1,11 y 1,04 direcciones efectivas. La que funciona conserva 1,97, las mismas que cualquier brazo con BatchNorm.

3. **La palanca no es BatchNorm, es la dimensionalidad.** BatchNorm es *una* forma de conseguirla; rollo sin él conserva 58/41 y llega a 0,9401. El término KL es otra: sus anclas son ortonormales, o sea le prescribe C direcciones por construcción, y sube las direcciones efectivas a $\approx 2{,}8$ en todas las configuraciones medidas.

4. **Ningún arreglo río abajo alcanza.** σ, los pesos por confianza, la mezcla marginal/condicional y la normalización por cotas leen todos la misma matriz de 3×3. Si esa matriz dice que la clase del medio está entre las otras dos, ninguno de ellos puede decir otra cosa.

5. **La mejor configuración medida, por familia, 5 semillas:**

familia	configuración	acierto
rollo	BatchNorm en la primera capa, con KL	1.0000 ± 0.000
toroides	BatchNorm en ambas capas ocultas, con KL	0.7657 ± 0.206
lunas	BatchNorm en la primera capa, con KL	0.8398 ± 0.038

contra 0,6769, 0,6299 y 0,4988 del punto de partida (BatchNorm en ambas capas ocultas, sin KL).

Todo número de este documento sale de una corrida medida sobre 5 semillas; el azar con 3 clases es 0,3333*. Las familias son de juguete y nada dice todavía que estos valores transfieran a los datos reales.*